

Evaluation d'impact : Économétrie des Panels

Chapitre 2: Les modèles de panel usuels - Rappels

Esther Delesalle

esther.delesalle@univ-paris1.fr

S1 2023-2024

Organisation du cours

- ▶ 1. Introduction aux données de panel
- ▶ 2. Les modèles de panel usuels
- ▶ 3. Estimation et Inférence statistique avec des modèles de panel
- ▶ 4. Applications (TD)


Chapitre 2 : Rappels des MCO

Chapitre 2: Les modèles en panel


Rappel : MCO

- ▶ Les modèles linéaires sur données de panel s'appuient sur mêmes outils que les MCO
 - ▶ Ces modèles sont des applications des MCO sur des données "transformées".
- La première partie de ce cours est un rappel des outils économétriques standards.


Rappel : MCO - régression linéaire simple




Rappel : MCO - régression linéaire simple




Rappel : MCO - régression linéaire simple



Rappel : MCO - régression linéaire simple



Rappel : MCO - régression linéaire simple



► OLS : $\min \sum_i^N (d_i)^2 = \min \sum_i^N (y_i - \beta_0 - \beta_1 x_i)^2 = \min S$

Rappel : MCO - régression linéaire simple

Propriétés des MCO:

Rappel : MCO - régression linéaire simple

Propriétés des MCO:

$$\begin{cases} E(u) = 0 \\ cov(x, u) = E(xu) = 0 \end{cases}$$

$$\begin{cases} E(y - \beta_0 - \beta_1 x) = 0 \\ E(x(y - \beta_0 - \beta_1 x)) = 0 \end{cases}$$

Sur un échantillon n , l'estimation des $\hat{\beta}$ permet de résoudre ces deux équations:

$$\begin{cases} \frac{1}{n} \sum_1^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \\ \frac{1}{n} \sum_1^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \end{cases}$$

D'après les propriétés de sommation:

- ▶ $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$
- ▶ $\frac{\partial^2 S}{\partial \beta_1^2} = 0 \Leftrightarrow \hat{\beta}_1 = \frac{COV(X, Y)}{V(X)}$

Rappel : MCO - regression linéaire multiple

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + u_i$$

- ▶ $\forall i=1,2, \dots, N$
- ▶ k variables

Rappel : MCO - regression linéaire multiple

$$\left\{ \begin{array}{l} y_{\mathbf{1}} = \beta_0 + \beta_1 x_{\mathbf{1}\mathbf{1}} + \beta_2 x_{\mathbf{2}\mathbf{1}} + \cdots + \beta_k x_{k\mathbf{1}} + u_{\mathbf{1}} \\ \cdots \\ y_{\mathbf{i}} = \beta_0 + \beta_1 x_{\mathbf{1}\mathbf{i}} + \beta_2 x_{\mathbf{2}\mathbf{i}} + \cdots + \beta_k x_{k\mathbf{i}} + u_{\mathbf{i}} \\ \cdots \\ y_{\mathbf{N}} = \beta_0 + \beta_1 x_{\mathbf{1}\mathbf{N}} + \beta_2 x_{\mathbf{2}\mathbf{N}} + \cdots + \beta_k x_{k\mathbf{N}} + u_{\mathbf{N}} \end{array} \right.$$

Rappel : MCO - regression linéaire multiple

$$\underset{N \times 1}{Y} = \underset{N \times (k+1)}{X'} \times \underset{(k+1) \times 1}{\beta} + \underset{N \times 1}{U}$$

$$\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_i \\ \dots \\ y_N \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & x_{2,1} & \dots & x_{k,1} \\ 1 & x_{1,2} & x_{2,2} & \dots & x_{k,2} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{1,i} & x_{2,i} & \dots & x_{k,i} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{1,N} & x_{2,N} & \dots & x_{k,N} \end{bmatrix} \times \begin{bmatrix} \beta_0 \\ \beta_1 \\ \dots \\ \beta_i \\ \dots \\ \beta_k \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \dots \\ u_i \\ \dots \\ u_N \end{bmatrix}$$

Rappel : MCO - regression linéaire multiple

$$\underset{N \times 1}{Y} = \underset{N \times (k+1)}{X'} \times \underset{(k+1) \times 1}{\beta} + \underset{N \times 1}{U}$$

Avec:

- ▶ Y = variable expliquée / dépendante
- ▶ X = variables explicatives / indépendantes
- ▶ β = coefficients à estimer
- ▶ U = termes d'erreur

Rappel : MCO - regression linéaire multiple

$$\underset{N \times 1}{Y} = \underset{N \times (k+1)}{X'} \times \underset{(k+1) \times 1}{\beta} + \underset{N \times 1}{U}$$

Avec:

$$\blacktriangleright \widehat{\beta_{MCO}} = (X'X)^{-1}(X'Y)$$

$$\blacktriangleright \widehat{V(\hat{\beta})} = \hat{\sigma}^2(X'X)^{-1}$$

En partant de l'hypothèse des MCO:

Rappel : MCO - regression linéaire multiple

$$\underset{N \times 1}{Y} = \underset{N \times (k+1)}{X'} \times \underset{(k+1) \times 1}{\beta} + \underset{N \times 1}{U}$$

Avec:

- ▶ $\widehat{\beta_{MCO}} = (X'X)^{-1}(X'Y)$
- ▶ $\widehat{V(\hat{\beta})} = \hat{\sigma}^2(X'X)^{-1}$

En partant de l'hypothèse des MCO:

- ▶ $X'U = 0$
 $X'(Y - X\hat{\beta}) = 0$
 $X'Y = X'X\hat{\beta}$

Rappel : MCO - regression linéaire multiple


$$\underset{N \times 1}{Y} = \underset{N \times (k+1)}{X} \times \underset{(k+1) \times 1}{\beta} + \underset{N \times 1}{U}$$

Hypothèses clés (identification et inférence) :

- ▶ Exogénéité : $COV(X, U) = 0$
→ les coefficients ne sont pas biaisés
- ▶ $U \hookrightarrow N(0, \sigma^2 I)$
→ variance efficace
 - ▶ Homocédasticité
 - ▶ Pas d'auto-corrélation

Rappel : MCO - regression linéaire multiple

L'hypothèse d'homocédasticité est-elle vérifiée?



Chapitre 2 : Rappels des MCO


Chapitre 2: Les modèles en panel

Introduction

- ▶ Les données de panel permettent d'utiliser plus d'informations que les données en coupe et les données en série temporelle, car elles contiennent à la fois :
 - ▶ variation entre les individus
 - ▶ variation entre les périodes temporelles
- ▶ Plusieurs modèles permettent de tenir compte de la structure particulière des données

→ Présentation des différents modèles linéaires possibles

Intuition



Modèle général

Dans la suite, on considèrera un modèle avec deux variables explicatives (ou deux groupes de variables) :

- ▶ $z_{i,t}$ = variable qui varie dans le temps et entre individus (exemple : salaire)
- ▶ z_i = variable qui varie entre individu, mais reste fixe dans le temps (exemple : lieu de naissance, nombre de frères et soeurs à la naissance)

$$y_{i,t} = \beta_0 + \underbrace{\beta_1 z_{i,t} + \beta_2 z_i}_{x'_{i,t} \beta} + u_i$$

Modèle poolé

Le modèle linéaire le plus restrictif est le modèle “poolé”:

$$y_{i,t} = \beta_0 + x'_{i,t}\beta + u_{i,t}$$

- Tous les paramètres sont constants.
Implications?

Modèle poolé

Le modèle poolé consiste à empiler toutes les observations :

$$\begin{pmatrix} y_{1,1} \\ \vdots \\ y_{1,T} \\ \vdots \\ y_{i,1} \\ \vdots \\ y_{i,T} \\ \vdots \\ y_{N,1} \\ \vdots \\ y_{N,T} \end{pmatrix} = Y$$

$$Y = \beta_0 + X' \beta + u$$

→ Modèle linéaire standard que l'on peut estimer par les MCO

Modèle poolé

- ▶ Ne tient pas compte du fait que certaines observations à différentes dates proviennent du même individu
 - ▶ Ni du fait que certaines observations sur différents individus proviennent de la même date
- Sans hypothèse supplémentaire, l'estimateur MCO n'est pas convergent

Effets individuels

On peut introduire dans le modèle un effet individuel, c_i :

$$y_{i,t} = \beta_0 + x'_{i,t}\beta + c_i + \epsilon_{it}$$

- ▶ Le terme c_i permet de tenir compte de l'hétérogénéité inobservée entre les individus
 - ▶ Il s'agit d'une composante individuelle fixe dans le temps: **régression sur variables indicatrices**.
- ▶ Le terme ϵ_{it} est la composante "transitoire" résiduelle.
- ▶ Peut-on estimer les c_i avec des données transversales?

Effets individuels

Le modèle implique que :

1. L'effet des variables explicatives observables (le vecteur β) est le même quel que soit l'individu et quelle que soit la date
2. L'effet des caractéristiques inobservables d'un individu (c_i) est le même quelle que soit la date
3. Représentation graphique?

Effets temporels

On peut introduire dans le modèle un effet du temps, λ_t :

$$y_{i,t} = \beta_0 + x'_{i,t}\beta + \lambda_t + \epsilon_{i,t}$$

- ▶ Le terme λ_t permet de tenir compte de l'effet du temps
- ▶ Il capte les chocs qui affectent tous les individus à une date donnée

Effets temporels

Le modèle implique que :

1. L'effet des chocs temporels inobservés (λ_t) est le même quel que soit l'individu
2. L'effet des variables explicatives observables (le vecteur β) est le même quel que soit l'individu et quelle que soit la date

Effets individuels et temporels

On peut introduire à la fois un effet individuel et un effet temporel :

$$y_{i,t} = \beta_0 + x'_{i,t}\beta + c_i + \lambda_t + \epsilon_{i,t}$$

- ▶ Mais les effets individuels et temporels ne sont pas complètement symétriques dans un panel
- ▶ Pourquoi?

Effets individuels et temporels

On peut introduire à la fois un effet individuel et un effet temporel :

$$y_{i,t} = \beta_0 + x'_{i,t}\beta + c_i + \lambda_t + \epsilon_{i,t}$$

- ▶ Mais les effets individuels et temporels ne sont pas complètement symétriques dans un panel
- ▶ Pourquoi? Parce que généralement N est grand par rapport à T

Effets individuels et temporels

- ▶ Effets temporels : parce que $T < N$, on peut estimer les λ_t de façon convergente quand $N \rightarrow \infty$
 - Il suffit d'ajouter une indicatrice par période
- ▶ Effets individuels : quand $N \rightarrow \infty$, le nombre de paramètres c_i à estimer tend vers l'infini aussi...
 - Peut-on estimer les effets individuels de façon convergente ? Veut-on les estimer ?
- **L'estimation des coefficients β va dépendre des hypothèses sur les effets individuels**

Effets individuels

- On considère le modèle :

$$y_{i,t} = \underbrace{\beta_1 z_{i,t} + \beta_2 z_i + \lambda_t}_{x'_{i,t} \beta} + \underbrace{c_i + \epsilon_{i,t}}_{u_{i,t}}$$

- On suppose l'exogénéité forte/stricte :
 $E[\epsilon_{it} | c_i, z_{i1}, \dots, z_{iT}] = 0, t = 1, \dots, T$
- C'est-à-dire : hypothèse que ϵ_{it} a :
- une espérance de zéro conditionnellement aux valeurs passées, présentes et futures des régresseurs.
- Équivalent à zéro covariance

Effets individuels non corrélés

- ▶ Cela revient à considérer que le terme inobservé c_i fait partie du terme d'erreur : $u_{it} = c_i + \epsilon_{it}$
- ▶ Alors, pour estimer le modèle par les MCO de façon convergente, il faut supposer :

$$\text{cov}(u_{it}, z_{it}) = \text{cov}(u_{it}, z_i) = 0$$

c'est-à-dire :

$$\begin{cases} \text{cov}(\epsilon_{it}, z_{it}) = \text{cov}(\epsilon_{it}, z_i) = 0 \\ \text{cov}(c_i, z_{it}) = \text{cov}(c_i, z_i) = 0 \end{cases}$$

- ▶ La deuxième hypothèse suppose que les effets individuels inobservés sont non corrélés aux variables explicatives

Effets individuels corrélés

- ▶ Si ce n'est pas le cas, alors même si : $cov(\epsilon_{it}, z_{it}) = cov(\epsilon_{it}, z_i) = 0$, les MCO ne sont pas convergents.
- ▶ le terme d'erreur, u_{it} n'est pas orthogonal aux variables explicatives

Exemple:

- ▶ Dans la relation entre nombre d'heures travaillées et salaire. Qu'en est-il?

Effets individuels corrélés

- ▶ Si ce n'est pas le cas, alors même si : $cov(\epsilon_{it}, z_{it}) = cov(\epsilon_{it}, z_i) = 0$, les MCO ne sont pas convergents.
- ▶ le terme d'erreur, u_{it} n'est pas orthogonal aux variables explicatives

Exemple:

- ▶ Dans la relation entre nombre d'heures travaillées et salaire. Qu'en est-il?
- ▶ Les caractéristiques individuelles inobservés du nombre d'heures (productivité) sont probablement aussi corrélées au salaire.

Effets individuels corrélés

- ▶ Comment identifier le modèle quand les effets individuels sont corrélés ?
- ▶ En utilisant la dimension temporelle des données de panels pour éliminer des effets individuels fixes dans le temps
- ▶ Ex: le modèle en différence entre deux dates, et le modèle dit à "effets fixes".

Exemple : modèle en différence première

Le modèle en différence entre deux dates consécutives :

$$y_{it} - y_{it-1} = (z_{it} - z_{it-1})\beta_1 + (\epsilon_{it} - \epsilon_{it-1})$$

⇒ Les effets fixes individuels sont éliminés

⇒ mais les β_2 et z_i aussi !!

► Hypothèse pour que l'estimateur MCO soit consistant:

$$\text{cov}(z_{it} - z_{it-1}, \epsilon_{it} - \epsilon_{it-1}) = 0$$

Exemple : modèle within

- Le modèle sur l'écart à la moyenne (modèle within) :

$$y_{it} - \bar{y}_i = (z_{it} - \bar{z}_i)\beta_1 + (\epsilon_{it} - \bar{\epsilon}_i)$$

⇒ Dans le modèle within, les effets fixes individuels sont éliminés

- Hypothèse: $cov((z_{it} - \bar{z}_i), (\epsilon_{it} - \bar{\epsilon}_i))=0$

Pour résumer : les modèles à effets "individuels"

- Ils s'écrivent ainsi :

$$y_{i,t} = \underbrace{\beta_0 + \beta_1 z_{i,t} + \beta_2 z_i}_{x'_{i,t} \beta} + \underbrace{c_i + \epsilon_{i,t}}_{u_{i,t}}$$

(version simplifiée de ce qu'on a vu précédemment).

- Chaque agent i a sa constante, mais toutes les pentes sont les mêmes entre agents.
- c_i variables aléatoires
 - Capture l'hétérogénéité inobservée invariante dans le temps

Deux types de modèles à effets "individuels" selon la nature de la corrélation entre ces effets individuels et les variables explicatives

- ▶ Il existe 2 variantes du modèle $y_{it} = c_i + x'_{it}\beta + \epsilon_{it}$ selon l'hypothèse sur c_i
 - ▶ Toutes deux décomposent l'erreur de mesure: c_i et ϵ_{it}
 - Modèles à erreurs composées
 - ▶ Toutes deux traitent c_i comme une v.a. inobservée
- ▶ Variante 1 : **modèle à effets fixes (EF)**
 - ▶ c_i est corrélé avec (la partie invariante au temps) des régresseurs observés x_{it}
 - ▶ C'est une forme d'hétérogénéité inobservée

Modèle à effets aléatoires

- ▶ Variante 2 : **modèle à effets aléatoires (EA)**

- ▶ c_i est distribué indépendamment de x

- ▶ On suppose que les effets aléatoires c_i et les termes d'erreurs ϵ_{it} sont iid et que :

$$\begin{cases} c_i \sim [c, (\sigma_c)^2] \\ \epsilon_i \sim [0, (\sigma_\epsilon)^2] \end{cases} \quad (1)$$