

Econométrie avancée : Économétrie des Panels

Les modèles de panel usuels : estimation et inférence

Esther Delesalle

esther.delesalle@univ-paris1.fr

S1 2024-2025

Introduction: Les modèles de panels usuels

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateurs qui requièrent la non-corrélation des effets individuels

- MCO poolés

- Estimateur Between

- Modèles à effets aléatoires

Choix de la famille des estimateurs

- Éléments de choix hors test

- Les tests statistiques

Chapitre 3 : Application

Introduction

Nous sommes dans le cadre suivant:

$$y_{i,t} = \underbrace{\beta_0 + \beta_1 z_{i,t} + \beta_2 w_i}_{x'_{i,t} \beta} + \underbrace{c_i + \epsilon_{i,t}}_{u_{i,t}}$$

$$y_{i,t} = x'_{i,t} \beta + u_{i,t}$$

Il y a 2 questions principales à se poser lorsqu'on cherche à estimer des modèles de panel :

1. **Problème d'estimation (variable omise):** Effets individuels c_i : corrélés aux variables explicatives ?
→ 2 groupes d'estimateurs.
2. **Problème d'inférence:** Comment estimer des écarts-types convergents étant donnée la structure de la corrélation entre les observations ?
 - ▶ Nous observons les mêmes individus à plusieurs dates : les erreurs ne sont certainement pas i.i.d
 - ▶ On parle d'auto-corrélation sérielle

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

1. Estimateur en Différences premières
2. Estimateur Within ou estimateurs à effets fixes

Estimateurs qui requièrent la non-corrélation des effets individuels

1. L'estimateur des MCO poolés
2. L'estimateur Between
3. L'estimateur à effets aléatoires

Introduction: Les modèles de panels usuels

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateurs qui requièrent la non-corrélation des effets individuels

- MCO poolés

- Estimateur Between

- Modèles à effets aléatoires

Choix de la famille des estimateurs

- Éléments de choix hors test

- Les tests statistiques

Chapitre 3 : Application

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Plaçons-nous dans le cas où les effets fixes individuels sont corrélés aux variables explicatives :

$$\text{cov}(c_i, x_{it}) \neq 0$$

→ Par ex : les compétences innées d'un individu (inobservables) peuvent être corrélées à son niveau de salaire. Si on cherche comprendre le lien entre niveau de salaire (x) et nombre d'heures travaillées (y), cette omission est problématique.

→ Pour estimer le modèle de façon convergente, il faut supprimer (ou "contrôler" pour) l'effet fixe individuel

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateur en différence première.

Il s'agit de l'estimateur des MCO dans le modèle en différence première (FD): on s'intéresse à la variation, d'une période à l'autre des variables du modèle

$$y_{i,t} = \beta_0 + \beta_1 z_{i,t} + \beta_2 w_i + c_i + \epsilon_{i,t}$$

$$t=1 \quad y_{i,1} = \beta_0 + \beta_1 z_{i,1} + \beta_2 w_i + c_i + \epsilon_{i,1}$$

$$t=2 \quad y_{i,2} = \beta_0 + \beta_1 z_{i,2} + \beta_2 w_i + c_i + \epsilon_{i,2}$$

$$\begin{aligned} \text{FD} \quad (y_{i,2} - y_{i,1}) &= \\ &(\beta_0 - \beta_0) + (\beta_1 z_{i,2} - \beta_1 z_{i,1}) + (\beta_2 w_i - \beta_2 w_i) + (c_i - c_i) + (\epsilon_{i,2} - \epsilon_{i,1}) \end{aligned}$$

$$\text{FD} \quad (y_{i,2} - y_{i,1}) = \beta_1 (z_{i,2} - z_{i,1}) + (\epsilon_{i,2} - \epsilon_{i,1})$$

$$\text{FD} \quad (y_{i,t} - y_{i,t-1}) = \beta_1 (z_{i,t} - z_{i,t-1}) + (\epsilon_{i,t} - \epsilon_{i,t-1})$$

⇒ Que constate-on ?

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateur en différence première.

Il s'agit de l'estimateur des MCO dans le modèle en différence première (FD): on s'intéresse à la variation, d'une période à l'autre des variables du modèle

$$y_{i,t} = \beta_0 + \beta_1 z_{i,t} + \beta_2 w_i + c_i + \epsilon_{i,t}$$

$$t=1 \quad y_{i,1} = \beta_0 + \beta_1 z_{i,1} + \beta_2 w_i + c_i + \epsilon_{i,1}$$

$$t=2 \quad y_{i,2} = \beta_0 + \beta_1 z_{i,2} + \beta_2 w_i + c_i + \epsilon_{i,2}$$

$$\begin{aligned} \text{FD} \quad (y_{i,2} - y_{i,1}) &= \\ &(\beta_0 - \beta_0) + (\beta_1 z_{i,2} - \beta_1 z_{i,1}) + (\beta_2 w_i - \beta_2 w_i) + (c_i - c_i) + (\epsilon_{i,2} - \epsilon_{i,1}) \end{aligned}$$

$$\text{FD} \quad (y_{i,2} - y_{i,1}) = \beta_1 (z_{i,2} - z_{i,1}) + (\epsilon_{i,2} - \epsilon_{i,1})$$

$$\text{FD} \quad (y_{i,t} - y_{i,t-1}) = \beta_1 (z_{i,t} - z_{i,t-1}) + (\epsilon_{i,t} - \epsilon_{i,t-1})$$

⇒ Que constate-on ? Les effets fixes sont éliminés

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateur en différence première.

$$\text{FD } (y_{i,t} - y_{i,t-1}) = \beta_1(z_{i,t} - z_{i,t-1}) + (\epsilon_{i,t} - \epsilon_{i,t-1})$$

$$\text{FD } \Delta y_i = \beta_1 \Delta z_i + \Delta \epsilon_i$$

- ▶ Les β sont estimées pour les individus pour lesquels $\Delta \neq 0$
 - ▶ i.e pour les individus pour lesquels il existe de la variation dans le temps
 - ▶ i.e interprétation en termes d'Average Treatment Effect on the Treated (ATT)
 - ▶ Si z est le nombre d'années d'études, alors on ne peut estimer le modèle que pour les individus pour lesquels z varie dans le temps
- ▶ Condition pour que l'estimation soit convergente est :
$$\text{cov}(z_{it} - z_{it-1}, \epsilon_{it} - \epsilon_{it-1}) = 0 \quad \forall i, t$$

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateur en différence première.

- ▶ Pas de constante dans ce modèle !
- ▶ Pas d'estimation des coefficients associés aux variables invariantes dans le temps
- ▶ L'hypothèse identifiante signifie que les changements dans les variables explicatives ne sont pas corrélés aux changements dans ϵ .

⇒ Tout choc qui affecte simultanément z et ϵ invalide cette hypothèse.
Exemple ?

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateur Within ou à Effets Fixes.

- ▶ Il s'agit de l'estimateur des MCO dans le modèle en écart à la moyenne :

$$y_{i,t} = \beta_0 + \beta_1 z_{i,t} + \beta_2 w_i + c_i + \epsilon_{i,t}$$

- ▶ Moyenne individuelle sur toute la période $\bar{y}_i = \beta_0 + \beta_1 \bar{z}_i + \beta_2 \bar{w}_i + \bar{c}_i + \bar{\epsilon}_i$
- ▶ On soustrait cette équation à l'équation de base :
- ▶ $(y_{i,t} - \bar{y}_i) = (\beta_0 - \beta_0) + \beta_1 (z_{i,t} - \bar{z}_i) + \beta_2 (w_i - \bar{w}_i) + (c_i - \bar{c}_i) + (\epsilon_{i,t} - \bar{\epsilon}_i)$
- ▶ $(y_{i,t} - \bar{y}_i) = \beta_1 (z_{i,t} - \bar{z}_i) + (\epsilon_{i,t} - \bar{\epsilon}_i)$
- ▶ $\bar{w}_i = w_i$ et $c_i = \bar{c}_i$

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateur Within ou à Effets Fixes.

- ▶ $(y_{i,t} - \bar{y}_i) = \beta_1(z_{i,t} - \bar{z}_i) + (\epsilon_i - \bar{\epsilon}_i)$
- ▶ Pas de constante dans le modèle
- ▶ Pas d'estimation des coefficients associés aux variables invariantes dans le temps
- ▶ Condition pour que l'estimation soit convergente est :
 $cov(z_{it} - \bar{z}_i, \epsilon_i - \bar{\epsilon}_i) = 0 \quad \forall i, t,$
- ▶ Condition suffisante: $cov(z_{it}, \epsilon_{it'}) = 0 \quad \forall i, t, t'$
- ▶ Les écarts-types doivent être corrigés afin d'être robustes à l'autocorrélation sérielle
- ▶ Même interprétation en termes d'ATT.
- ▶ Quid des individus observés qu'à une date?

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateur Within ou à Effets Fixes.

L'estimateur Within est équivalent à l'estimateur des MCO dans le modèle avec indicatrices individuelles

→ on rajoute les indicatrices individuelles à la main:

- ▶ $y_{i,t} = \beta_0 + \beta_1 z_{i,t} + \beta_2 w_i + \delta_i + \epsilon_{i,t}$
- ▶ Revient à sortir les effets fixes du terme d'erreur en les estimant
- ▶ Peut devenir compliqué si N est grand
- ▶ Dans ce cas, l'intérêt de l'estimateur Within est de ne pas nécessiter l'estimation des δ_i

Comparaison entre l'estimateur Différences premières (D1) et l'estimateur Within

- ▶ L'estimateur D1 est consistant pour β dans tous les modèles, comme l'estimateur Within.
- ▶ Pareillement, les coefficients des régresseurs invariants dans le temps ne sont pas identifiés.
- ▶ D1 est moins efficient que within car utilise moins de données s'il y a plus de deux vagues.

Introduction: Les modèles de panels usuels

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateurs qui requièrent la non-corrélation des effets individuels

- MCO poolés

- Estimateur Between

- Modèles à effets aléatoires

Choix de la famille des estimateurs

- Éléments de choix hors test

- Les tests statistiques

Chapitre 3 : Application

Estimateurs qui requièrent la non-corrélation des effets individuels

Plaçons-nous maintenant dans le cas où les effets fixes individuels ne sont pas corrélés aux variables explicatives :

$$\text{cov}(c_i, x_{it}) = 0$$

→ il y a de l'hétérogénéité individuelle inobservée, mais elle n'est pas corrélée aux variables explicatives.

Estimateur MCO poolé

- Le modèle poolé sur l'ensemble des observations équivaut à :

$$y_j = x_j' \beta + u_j$$

,

$$j = 1, \dots, NT$$

- L'estimation par les MCO est convergente si :

$$\text{Cov}(u_j, x_j) = \text{Cov}(u_{j,t}, x_{i,t}) = 0, \forall i, t$$

Conditions suffisantes:

$$\begin{cases} \text{Cov}(c_j, x_j) = \text{Cov}(c_i, x_{i,t}) = 0, \forall i, t \\ \text{Cov}(\epsilon_j, x_j) = \text{Cov}(\epsilon_{i,t}, x_{i,t}) = 0, \forall i, t \end{cases}$$

→ Si N (ou T) est grand, l'estimateur est convergent.

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur MCO poolé

- ▶ Quel est alors l'avantage d'utiliser des données de panel ?

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur MCO poolé

- ▶ Quel est alors l'avantage d'utiliser des données de panel ?
 - ▶ On pourrait estimer le modèle sur les données d'une seule période en coupe transversale
 - ▶ Par rapport à des données en coupe, on dispose de T fois plus de données
- L'estimateur obtenu est donc plus précis

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur MCO poolé

- ▶ Si on utilisait T coupes transversales sur des individus différents, on obtiendrait plus d'information que dans le panel
- ▶ Dans un panel, une partie de l'information est répétée
- Il faut en tenir compte dans l'estimation des écarts-types

Rappel: écart-type robuste en coupe transversale

- En coupe transversale, les erreurs standard sont calculées sous l'hypothèse que les termes d'erreur sont indépendamment et identiquement distribués (iid)

$$\begin{cases} var(u_i) = \sigma^2 \forall i \\ cov(u_i, u_{i'}) = 0 \forall i \neq i' \end{cases}$$

- ▶ En données de panel, l'hypothèse d'écarts-types i.i.d est probablement invalidée.
- ▶ Cela implique :

$$\begin{cases} \text{var}(u_{it}) = \sigma^2 \forall i, t \\ \text{cov}(u_{it}, u_{it'}) = 0 \forall i, t \neq t' \\ \text{cov}(u_{it}, u_{i't}) = 0 \forall t, i \neq i' \end{cases}$$

- ▶ La condition $cov(u_{it}, u_{it'}) = 0$ est donc peu vraisemblable:

Les termes d'erreur du modèle sont corrélés pour les différentes observations d'un même individu:

- ▶ $cov(u_{it}, u_{it'}) = Var(c_i) = \sigma_c^2$
- ▶ On parle d'auto-corrélation sérielle des résidus
- ▶ L'auto-corrélation des résidus dans le temps est généralement grande
- ▶ Les écarts-types estimés par les MCO sont biaisés
- ▶ Ne pas en tenir compte conduit à sous-estimer la variance de l'estimateur

MCO poolés

L'estimateur des MCO sur le modèle poolé est **convergent**, mais, du fait de la structure de la corrélation, il n'est **pas efficace**.

→ Nécessité de toujours utiliser des écarts-types corrigés pour les estimateurs POLS.

`regress y x, robust cluster(id)`

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur Between

- ▶ L'estimation between est l'estimation par les MCO du modèle en moyenne individuelle
- ▶ $\bar{y}_i = \beta_0 + \beta_1 \bar{z}_i + \beta_2 \bar{w}_i + \bar{c}_i + \bar{\epsilon}_i$
- ▶ L'estimateur MCO poolé utilise la variation dans les dimensions inter et intra-individuelle
- ▶ L'estimateur between utilise uniquement la dimension inter-individuelle

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur Between

- Conditions pour la convergence:
 - $cov(\overline{x_i}, \overline{u_i}) = 0 \Leftrightarrow cov(\overline{x_i}, c_i + \overline{\epsilon_i}) = 0$
- L'estimation between nécessite donc une hypothèse d'exogénéité plus forte, puisqu'il faut :

$$\begin{cases} cov(\overline{x_i}, c_i) = 0 \\ cov(\overline{x_i}, \overline{\epsilon_i}) = 0 \end{cases}$$

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur Between

- ▶ Une condition suffisante est :

$$\begin{cases} cov(x_{i,t}, c_{i,\cdot}) = 0, \forall i, t \\ cov(x_{i,t}, \epsilon_{i,t'}) = 0, \forall i, t, t' \end{cases}$$

- ▶ Pour chaque individu, la valeur courante $x_{i,t}$ doit être non corrélée à tous les chocs présents, passés ou futurs $\epsilon_{i,t}$.
- ▶ Une observation par individu
 - ▶ La correction des écarts-types est moins problématique.
 - ▶ On peut appliquer des corrections classique d'hétéroscédasticité.

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur Between

- ▶ Même si les estimateurs between sont convergents, les estimateurs des MCO poolées et à effets aléatoires (prochain modèle) sont plus efficaces.
- ▶ En pratique, ce modèle est très peu utilisé, mais :
 - ▶ permet de comprendre les tendances moyennes
 - ▶ est une des composantes du modèle à effets aléatoires.

Between

- ▶ L'estimateur between est inconsistant si le modèle est à effets fixes (car les erreurs seront corrélées aux variables explicatives).
- ▶ L'estimateur Between gaspille beaucoup d'informations.

Modèle à effets aléatoires

- ▶ Le modèle se présente ainsi:

$$y_{it} = c_i + x_{it}\beta + \epsilon_{it}$$

- ▶ avec l'hypothèse supplémentaire que les effets individuels inobservables sont des variables aléatoires qui sont distribuées indépendamment des régresseurs.
- ▶ On suppose en général en outre que :

$$\begin{cases} c_i \sim [c, (\sigma_c)^2] \\ \epsilon_i \sim [0, (\sigma_\epsilon)^2] \end{cases}$$

à savoir que les effets aléatoires et le terme d'erreur sont iid.

- ▶ Le modèle à effets aléatoires peut être vu comme un cas spécifique du modèle poolé dans lequel les c_i rentre dans le terme d'erreur

Modèle à effets aléatoires

- Le modèle à effets aléatoires est équirelié:

$$Cov(c_i + \epsilon_{it}, c_i + \epsilon_{is}) = \begin{cases} \sigma_c^2, t \neq s \\ \sigma_c^2 + \sigma_\epsilon^2, t = s \end{cases}$$

- Cela signifie que les OLS poolés sont consistents, dans ce modèle, mais pas efficient.

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur à effets aléatoires (Random effect estimator)

- ▶ Cet estimateur est équivalent à l'estimateur des moindres carrés généralisés (MCG).
- ▶ Suppose que les effets fixes, c_i sont parfaitement aléatoires
- ▶ Il s'agit de l'estimateur des MCO sur le modèle transformé :
 - ▶ $(y_{i,t} - \lambda \bar{y}_i) = \beta_1(x_{i,t} - \lambda \bar{x}_i) + (u_{i,t} - \lambda \bar{u}_i)$
 - ▶ avec : $\lambda = 1 - \sqrt{\frac{\sigma_\epsilon^2}{\sigma_\epsilon^2 + T\sigma_c^2}}$
 - ▶ où: σ_ϵ^2 et σ_c^2 désignent les variances des $\epsilon_{i,t}$ et des c_i , respectivement
 - ▶ empiriquement, ils sont estimés par: $\hat{\sigma}_\epsilon^2$ et $\hat{\sigma}_c^2$

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur à effets aléatoires (Random effect estimator)

- ▶ Principe :
 - ▶ Une observation provenant du même individu apporte moins d'information nouvelle qu'une observation provenant d'un individu différent
 - ▶ Le principe des MCG est de pondérer les observations selon l'information qu'elles apportent (between ou within)
- Chaque observation est pondérée en tenant compte de la forme de la matrice de variance covariance des résidus

Estimateurs qui requièrent la non-corrélation des effets individuels

Estimateur à effets aléatoires (Random effect estimator)

$$\blacktriangleright (y_{i,t} - \lambda \bar{y}_i) = \beta_1 (x_{i,t} - \lambda \bar{x}_i) + (u_{i,t} - \lambda \bar{u}_i)$$

$$\text{avec : } \lambda = 1 - \sqrt{\frac{\sigma_\epsilon^2}{\sigma_\epsilon^2 + T\sigma_c^2}}$$

► Remarques :

- Si $\sigma_c = 0$, alors $\lambda = 0$ et on retrouve l'estimateur des MCO poolés
 - Les observations ne sont pas corrélées dans le temps pour un même individu et l'estimateur des MCO poolés est l'estimateur efficace (tous les individus ont le même c_i qui passe donc dans la constante β_0)
- Si $T \Rightarrow \infty$, alors $\lambda = 1$ et on retrouve l'estimateur Within
- En pratique, si $0 < \lambda < 1$, on peut montrer que l'estimateur des MCG est une moyenne pondérée des estimateurs Between et Within

- ▶ L'estimateur des Effets aléatoires (RE) est complètement efficient sous le modèle RE.
- ▶ En revanche, il n'est pas consistant si les effets fixes sont corrélés.

Nouvelle question :

- ▶ Comment estimer des écarts-types convergents étant donnée la structure de la corrélation entre les observations ?

Estimation des écarts-types

Tous les estimateurs sont des MCO sur une transformation du modèle initial :

$$y_{i,t} = x'_{i,t}\beta + \underbrace{c_i + \epsilon_{i,t}}_{u_{i,t}}$$

- ▶ A moins qu'il n'y ait pas d'hétérogénéité inobservée ($\sigma_c = 0$), alors les termes d'erreur du modèle sont corrélés pour les différentes observations d'un même individu
- ▶ On parle d'auto-corrélation sérielle des résidus
- ▶ L'hypothèse $\text{var}(u|x) = \sigma^2 I_{NT}$ n'est pas vérifiée dans ce modèle
- ▶ Les écarts-types estimés par les MCO sont biaisés
 - ▶ Variance sous-estimée, tests de significativité des coefficients sur-estimés
 - ▶ L'hypothèse de nullité rejetée trop fréquemment.

Estimation des écarts-types

- ▶ Il existe des corrections statistiques permettant de prendre en compte l'autocorrélation sérielle (non-démontré dans le cadre de ce cours).
- ▶ Analogue à la matrice de White (pour l'hétéroscédasticité) mais qui tient compte aussi de l'existence de "clusters" individuels (l'autocorrélation sérielle).
- ▶ Les individus sont observés plusieurs fois, donc leurs observations (et donc les résidus correspondants sont a priori corrélés).
- ▶ Les procédures des logiciels (pour la plupart) corrigent ces écarts-types.
- ▶ Les écarts-types robustes en panel sont un exemple d'écarts-types "clusterisés", c'est-à-dire robustes de toute corrélation entre les termes d'erreur au sein du "cluster" d'observations constitué par chaque individu

Introduction: Les modèles de panels usuels

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateurs qui requièrent la non-corrélation des effets individuels

- MCO poolés

- Estimateur Between

- Modèles à effets aléatoires

Choix de la famille des estimateurs

- Éléments de choix hors test

- Les tests statistiques

Chapitre 3 : Application

Causalité

- ▶ Le modèle EF peut établir la causalité avec moins d'hypothèses que dans le cas:
 - ▶ De données en coupe transversale
 - ▶ Du modèle poolé
 - ▶ Du modèle avec EA
- ▶ Dans quelques cas, la causalité est claire, donc EA est approprié:
 - ▶ Dans le cas d'une expérience contrôlée, la causalité est claire:
Le traitement x_{it} est alloué aléatoirement, donc non-corrélé à c_i
 - ▶ Parfois, on ne veut mesurer que la corrélation, pas la "causation"
 - ▶ Pour de la prédiction
 - ▶ EA est alors suffisant

Causalité

- ▶ En général, les économistes préfèrent une approche EF car ils veulent mesurer la causalité
 - ▶ avec des données observationnelles
 - ▶ plutôt qu'expérimentales
- ▶ Dans ce cas, utiliser EA ou MCO n'aboutit qu'à une corrélation spurieuse souvent due à une hétérogénéité inobservée:
- ▶ EF élimine l'hétérogénéité inobservée
 - ▶ L'effet causal de x sur y est mesuré par la corrélation entre des changements individuels dans y et dans x

Echantillon

Souvent en économie, l'échantillon porte sur :

- ▶ des agents complexes : personnes ou pays
- ▶ des phénomènes expliqués complexes
 - ▶ travail (chômage, salaire, participation....)
 - ▶ revenu, croissance, vote, espérance de vie...
- ▶ En conséquence, il est difficile d'argumenter qu'il ne manque pas une caractéristique:
 - ▶ histoire, géographie, droit... pour les pays
 - ▶ psychologie, culture... pour les personnes
- ▶ Donc, EF par défaut
- ▶ EA doit être justifié

Faiblesse des EF en pratique

- ▶ L'estimation des coef. des régresseurs invariants dans le temps n'est pas possible avec EF.
 - ▶ Les coef. des régresseurs peu variables dans le temps sera imprécise.
 - ▶ Souvent, la variance inter est forte par rapport à la variation intra (variation dans le temps)
- ▶ La prédiction de la moyenne conditionnelle n'est pas consistante :
 - ▶ car les effets individuels c_i ne sont pas estimés de façon consistante
- ▶ EF fait moins d'hyp que EA sur l'hétérogénéité inobservée
 - ▶ Mais il faut que celle-ci soit constante dans le temps.

Quelle famille d'estimateurs?

- ▶ Comment choisir un estimateur plutôt qu'un autre?
- ▶ Intuition économique

Quelle famille d'estimateurs?

Effets individuels corrélés ou non corrélés?

- ▶ Pour cela, nous utilisons le *test d'Hausman*
 - ▶ H_0 : les effets individuels c_i ne sont pas corrélés aux variables explicatives
 - ▶ H_1 : les effets individuels c_i sont corrélés aux variables explicatives
- ▶ Si on rejette H_0 : alors ils faut préférer des modèles Within (différences premières ou effets fixes)
- ▶ Si on ne rejette pas H_0 : alors ils faut préférer des modèles à effets aléatoires (random-fixed effects).

Quelle famille d'estimateurs?

Effets individuels corrélés ou non corrélés?

En pratique sur Stata

1. estimation des EF et stockage de la régression

- ▶ `xtreg y x , fe`
- ▶ `eststo fe`

2. Estimation des EA et stockage de la régression

- ▶ `xtreg y x , re`
- ▶ `eststo re`

3. Administration du test d'hausman suivie du nom donné à chacune des deux régressions

- ▶ `hausman fe re, sigmamore`

Quelle famille d'estimateurs?

Effets individuels corrélés ou non corrélés?

Remarques

- ▶ Le test d'Hausman repose sur des hypothèses fortes
- ▶ Il n'est pas très robuste si les estimateurs FE et RE ne sont pas bien estimés
- ▶ A prendre avec précaution !
- ▶ Il existe des procédures pour rendre ce test plus robuste, pour plus de précisions voir version bootstrappée robuste à l'hétéroscédasticité :
 - ▶ Cameron, A. C. & Trivedi, P. K. Microeconometrics Using Stata, Revised Edition Stata Press, 2010, p. 267.

Parmi la famille des effets aléatoires :

Effets aléatoires ou MCO poolés?

- ▶ Pour cela, nous utilisons le *test du Lagrangien de Breusch-Pagan*
 - ▶ $H_0 : \sigma_{c_i} = 0 \rightarrow$ pas d'effets de panel, tous les individus ont le même c_i
 - ▶ $H_1 : \sigma_{c_i} \neq 0 \rightarrow$ effets de panel à prendre en compte
- ▶ Si on rejette H_0 : alors ils faut préférer un modèle à effets aléatoires.
- ▶ Si on ne rejette pas H_0 : alors ils faut préférer des modèles MCO poolés.

Parmi la famille des effets aléatoires :

Effets aléatoires ou MCO poolés?

En pratique sur Stata

1. Estimation des EA

► `xtreg y x , re vce(cluster id)`

2. Administration du test de Breusch-Pagan :

► `xttest0`

Parmi la famille des effets fixes:

Effets fixes ou MCO poolés?

- ▶ Pour cela, nous utilisons le *test de Fisher*
 - ▶ H_0 : Tous les $c_i = 0 \rightarrow$ pas d'effets de panel
 - ▶ H_1 : Au moins un $c_i \neq 0 \rightarrow$ effets de panel à prendre en compte
- ▶ Si on rejette H_0 : alors ils faut préférer un modèle à effets fixes
- ▶ Si on ne rejette pas H_0 : alors ils faut préférer des modèles MCO poolés.

Parmi la famille des effets fixes:

Effets fixes ou MCO poolés?

En pratique sur Stata

1. Estimation des EA

► `xtreg y x , fe`

2. La statistique de Fisher est indiquée en bas du tableau de sortie

```
. * Within or FE estimator
. xtreg l wage exp exp2 wks ed union ind occ, fe
note: ed omitted because of collinearity

Fixed-effects (within) regression              Number of obs   =   3696
Group variable: id                            Number of groups =   528

R-sq:  within = 0.6558                        Obs per group:  min =    7
        between = 0.0228                      avg       =   7.0
        overall = 0.0427                      max       =    7

                                         F(6,3162)        =   1004.25
corr(u_i, Xb)  = -0.9223                    Prob > F         =    0.0000

-----+-----
      |_wage_|      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-----+-----
      |exp|      .1149389   .0026801    42.89  0.000    .1096841   .1201938
      |exp2|     -.0004347   .0000584    -7.44  0.000   -.0005491   -.0003202
      |wks|      .0004693   .0006576     0.71  0.476   -.0008201    .0017587
      |ed|      (omitted)
      |union|     .0316998   .0159769     1.98  0.047    .0003736    .063026
      |ind|     .0182395   .0160431     1.14  0.256   -.0132165    .0496954
      |occ|     -.0113013   .0146455    -0.77  0.440   -.0400169    .0174144
      |_cons|    4.600501   .044283    103.89  0.000    4.513675    4.687328
-----+-----
      |sigma_u|    1.047369
      |sigma_e|    .1534777
      |rho|     -.97997847   (fraction of variance due to u_i)
-----+-----
F test that all u_i=0:      F(527, 3162) =    33.82      Prob > F = 0.0000
```

Data

Parmi la famille des effets fixes:

Effets fixes ou différences premières?

En pratique sur Stata

- ▶ Si $T = 2$ les deux estimateurs sont identiques
- ▶ Si $T > 2$ les estimateurs sont différents mais les deux sont non-biaisés et convergents
- ▶ Si N est grand et T est petit, les effets fixes sont généralement plus efficaces.

Introduction: Les modèles de panels usuels

Estimateurs qui ne requièrent pas la non-corrélation des effets individuels

Estimateurs qui requièrent la non-corrélation des effets individuels

- MCO poolés

- Estimateur Between

- Modèles à effets aléatoires

Choix de la famille des estimateurs

- Éléments de choix hors test

- Les tests statistiques

Chapitre 3 : Application

Quelles commandes sous Stata?

xtset id time

Estimateur Within ou estimateurs à effets fixes

- ▶ `xtreg REGRESSION, fe vce(cluster id)`

Estimateur LSDV

- ▶ `reg REGRESSION i.id , vce(cluster id)`

First Differences

- ▶ `regress D.(REGRESSION), noconstant`
- ▶ Attention ! la variable de temps déclarée doit exprimer les périodes de manière consécutive (t=1,2,3) → pensez à transformer vos variables de temps.

Quelles commandes sous Stata?

xtset id time

Random effects

- ▶ `xtreg REGRESSION, re theta vce(cluster id)`

Pooled OLS

- ▶ `reg REGRESSION, robust vce(cluster id)`

Between

- ▶ `xtreg REGRESSION, be`