

Évaluation d'impact : Économétrie des Panels

Chapitre 1: Introduction

Esther Delesalle

esther.delesalle@univ-paris1.fr

S1 2023-2024

Organisation du cours

- ▶ Évaluation d'impact : 27 heures
 - ▶ 15 heures de CM
 - ▶ 12 heures d'application sur STATA en demi-groupes
- ▶ Programme:
 - ▶ Économétrie de panel (deux cours CM)
 - ▶ Difference-in-difference
 - ▶ Régression sur discontinuité
 - ▶ Synthetic control et méthode de matching

Organisation du cours

Évaluation : Contrôle continu (pondération et dates indicatives)

- ▶ Examen sur table de 2 heures : 60 % de la note finale
 - ▶ 6 février
- ▶ Devoir de travaux dirigés
 - ▶ Document avec les réponses aux questions et les tableaux de résultats
 - ▶ Ajouter les codes STATA en Annexe
 - ▶ Soigner la présentation!
 - ▶ Relevé au sort (au moins une note)

Chapitre 1 : Cours

Chapitre 1 : Application

Introduction

Les données de panel : observations répétées d'une même unité sur plusieurs périodes temporelles

Un panel comprend deux dimensions :

- ▶ Une dimension individuelle, indicée par $i = 1, \dots, N$
- ▶ Une dimension temporelle, indicée par $t = 1, \dots, T$

Introduction

- ▶ Le nombre d'individus N est grand par rapport au nombre de périodes T

Exemples:

- ▶ Données sur plusieurs pays observés pendant plusieurs années
- ▶ Données sur des entreprises observées tous les mois
- ▶ Données sur des ménages enquêtés tous les deux ans

Avantage des données de panel

Parce qu'on dispose de plusieurs observations pour une même unité :

- ▶ Les données de panel permettent une meilleure précision d'estimation
- ▶ Elles permettent d'analyser des mécanismes économiques dynamiques
- ▶ Elles permettent de mettre en place de nouvelles méthodes pour identifier des effets causaux

Des méthodes spécifiques

- ▶ Parce que les données portent sur un même individu observé à des dates différentes
 - ▶ et sur des individus différents observés à une même date:
- Il faut tenir compte du lien de corrélation entre les observations d'un même individu / d'une même date
- ▶ L'objectif du cours est:
 - ▶ de présenter les spécificités des données de panel
 - ▶ de présenter les méthodes d'estimation adéquates

Organisation du cours

- ▶ 1. Introduction aux données de panel
- ▶ 2. Les modèles de panel usuels
- ▶ 3. Inférence statistique avec des modèles de panel
- ▶ 4. Applications des données de panel (TD)

Références

- ▶ Angrist, J. D., & Pischke, J. S. (2008). Mostly harmless econometrics: An empiricist's companion. Princeton university press.
- ▶ Cameron, A. C., & Trivedi, P. K. (2009). Microeconometrics using stata (Vol. 5). College Station, TX: Stata press.
- ▶ Wooldridge, J. M. (2016). Introductory econometrics: A modern approach. Nelson Education.

Structure des données de panel


- ▶ Les données observées sont de la forme $(x_{it}, y_{it})_{i=1,\dots,N;t=1,\dots,T}$
- ▶ y_{it} est la valeur de la variable d'intérêt pour l'individu i à la date t
- ▶ x_{it} est un vecteur de K variables explicatives pour l'individu i à la date t

Structure des données de panel

En coupe transversale, on observe N individus à une date donnée



Structure des données de panel




Structure des données de panel

En série temporelle, on observe un individu à T dates différentes




Structure des données de panel




Structure des données de panel

En panel, on observe N individus à T différentes dates



Structure des données de panel



Panel cylindré


Panel cylindré : un panel est dit cylindré si tous les individus sont observés à toutes les dates:

- ▶ Quelle que soit la date, le même échantillon d'individus est observé
- ▶ Pour chaque individu, le même nombre de dates est observé

Panel non cylindré : attrition

Un panel peut être non cylindré s'il y a de l'attrition


Attrition : une partie des individus cessent d'être observés avant la dernière date du panel



Panel non cylindré : renouvellement

Un panel peut être non cylindré si l'échantillon est renouvelé


Renouvellement: une partie des individus commencent à être observés après la première date du panel



Panel non cylindré : attrition et renouvellement

Un panel peut être non cylindré s'il y a renouvellement et attrition

Panel rotatif : les individus qui sortent du panel sont "remplacés" par des individus qui rentrent dans le panel



Panel non cylindré

- ▶ Les panels non cylindrés posent la question de la sélection des observations
- ▶ Si l'attrition ou le renouvellement ne sont pas aléatoires, alors il faut tenir compte du fait que les observations restantes/entrantes sont sélectionnées
- ▶ Exemple :
 - ▶ L'échantillon démographique permanent (EDP)
 - ▶ Panel Study of Income Dynamics (PSID)

Exemple : l'EDP

- ▶ L'échantillon démographique permanent (EDP)
- ▶ Informations issues de :
 - ▶ Fichiers d'état civil
 - ▶ Recensements de la population
 - ▶ Fichier électoral
 - ▶ Panel salariés
 - ▶ Données socio-fiscales
- ▶ Échantillon au 4/100ème de la population française
- ▶ Enrichissement permanent : tous les individus nés les 4 premiers jours des mois d'octobre, janvier, avril et juillet
- ▶ Panel non cylindré :
 - ▶ Entrée à la naissance
 - ▶ Attrition en cas de décès

Exemple : Panels d'élèves

- ▶ Depuis 1989, le service statistique du ministère de l'éducation construit des panels d'élèves
- ▶ Panel 2007 : échantillon de 35 000 entrants en 6ème en 2007
- ▶ Enquête de suivi du parcours scolaire, environnement familial
- ▶ Évaluations spécifiques
- ▶ Résultats aux examens nationaux
- ▶ Panel non cylindré :
 - ▶ Attrition possible en cas de changement d'académie

Pseudo-panel

- ▶ La spécificité des données de panel est que l'on observe les mêmes individus à différentes périodes
- ▶ Il est courant aussi d'observer des individus différents à différentes périodes
- ▶ On parle de pseudo-panel ou de données en coupes répétées

Exemples:

- ▶ Cohortes de classes répétées
- ▶ Enquête logement : des ménages représentatifs différents sont échantillonnés tous les 4 ans

Conditions:

Pseudo-panel

- ▶ La spécificité des données de panel est que l'on observe les mêmes individus à différentes périodes
- ▶ Il est courant aussi d'observer des individus différents à différentes périodes
- ▶ On parle de pseudo-panel ou de données en coupes répétées

Exemples:

- ▶ Cohortes de classes répétées
- ▶ Enquête logement : des ménages représentatifs différents sont échantillonnés tous les 4 ans

Conditions:

- ▶ Les observations observées par groupe sont représentatives du groupe
- ▶ Même processus de sélection entre chaque groupe

Avantages:

Pseudo-panel

- ▶ La spécificité des données de panel est que l'on observe les mêmes individus à différentes périodes
- ▶ Il est courant aussi d'observer des individus différents à différentes périodes
- ▶ On parle de pseudo-panel ou de données en coupes répétées

Exemples:

- ▶ Cohortes de classes répétées
- ▶ Enquête logement : des ménages représentatifs différents sont échantillonnés tous les 4 ans

Conditions:

- ▶ Les observations observées par groupe sont représentatives du groupe
- ▶ Même processus de sélection entre chaque groupe

Avantages:

- ▶ Application des méthodes de panel

Panel sans données temporelles

- ▶ L'économétrie des données de panel peut aussi être utilisée pour des données sans dimension temporelle
- ▶ Exemple : données de flux migratoires

$$Y_{ij} = \alpha X_i + \gamma X_j + \beta X_{ij} + \epsilon_{ij}$$

- ▶ Y_{ij} = flux de i vers j
- ▶ X_i = caractéristiques du pays d'origine
- ▶ X_j = caractéristiques du pays de destination
- ▶ X_{ij} = caractéristiques bilatérales (distance)

Plus de deux dimensions

- ▶ L'économétrie des données de panel peut être généralisée à plus de deux dimensions
- ▶ Exemple : données de flux migratoires en panel

$$Y_{ijt} = \alpha X_{it} + \gamma X_{jt} + \beta X_{ijt} + \epsilon_{ijt}$$

- ▶ Exemple : panel d'élèves (i) dans des établissements scolaires (j), observés à plusieurs dates (t).

Dimensions inter et intra

- ▶ Parce qu'elle permettent d'observer plusieurs individus à plusieurs périodes, il y a deux dimensions d'analyse des données de panel:
 - ▶ Variation inter-individuelle (Between) : Variation entre les individus
 - ▶ Variation intra-individuelle (Within): Variation temporelle pour un même individu

Exemple : Salaire et temps de travail

Cameron and Trivedi (2005) : Quel est l'impact du salaire sur le nombre d'heures travaillées ?

- Estimation:

$$\ln hours_{it} = \alpha_i + \beta \log(wages_{it}) + \epsilon_{it} \quad (1)$$

- D'après la théorie économique :

Exemple : Salaire et temps de travail


Cameron and Trivedi (2005) : Quel est l'impact du salaire sur le nombre d'heures travaillées ?

- ▶ Estimation:

$$\ln hours_{it} = \alpha_i + \beta \log(wages_{it}) + \epsilon_{it} \quad (1)$$

- ▶ D'après la théorie économique : Effet ambigu
 - ▶ Effet de revenu : relation négative
 - ▶ Effet de substitution : relation positive
- ▶ Panel de 532 hommes sur 10 ans de 1979 à 1988 (Ziliak, 1997)

Exemple : Salaire et temps de travail



Exemple : Salaire et temps de travail




$$\ln hours_i = \alpha + \beta \log(wages_i) + \epsilon_i \quad (2)$$

- ▶ Montre une relation positive entre (log) salaire horaire et (log) nombre d'heures travaillées
- ▶ Pente = 0.083
- ▶ Cette relation est due à la fois à la dimension inter- et intra-individuelle

Dimension inter (between)


Un point = moyenne individuelle sur les 10 ans



- ▶ Relation positive mais plus faible : pente = 0.067
- ▶ Régresse $(\bar{y}_i)$ sur $(\bar{x}_i)$

Dimension intra (within)

Un point = écart au salaire moyen de l'individu sur la période



- Relation positive mais plus grande : pente = 0.168
- Régresse $(y_{it} - \bar{y}_i)$ sur $(x_{it} - \bar{x}_i)$

Dimensions inter et intra

- ▶ Ces deux dimensions mesurent des choses différentes
 - ▶ Deux dimensions confondues : des salaires plus élevés sont associés à des nombres d'heures travaillées plus élevées
 - ▶ Dimension between : les individus qui ont un salaire moyen plus élevé travaillent plus
 - ▶ Dimension within : les individus travaillent plus lorsque leur salaire est supérieur à leur salaire moyen
- Réaction plus forte entre les individus que lorsque l'on exploite la variation temporelle

Biais d'hétérogénéité

Distinguer les deux dimensions permet aussi de mieux comprendre les différents types de biais possibles:

- ▶ Graphique between : est-ce que les individus qui ont un salaire moyen plus élevé travaillent plus ?
- ▶ Il est probable que les individus qui ont un salaire plus élevé ont des caractéristiques inobservables particulières
- ▶ Par exemple, ils ont une dés-utilité plus faible à travailler
- La relation est sur-estimée
- Le biais est dû à une hétérogénéité entre les individus

Biais de simultanéité

- ▶ Graphique within : est-ce que les individus qui ont un salaire plus élevé que leur salaire moyen travaillent plus ?
- ▶ Cela pourrait être dû à des chocs de productivité à une date donnée
- ▶ Par exemple, un choc de santé qui diminue salaire et nombre d'heures travaillées
- La relation est sur-estimée
- Le biais est dû à des chocs qui influent simultanément le salaire et le nombre d'heures

Décomposition de la variance

- Les dimensions inter et intra recouvrent toute l'information des données de panel

$$\sum_{i=1}^N \sum_{t=1}^T (z_{it} - \bar{z})^2 = \sum_{i=1}^N \sum_{t=1}^T (z_{it} - \bar{z}_i)^2 + \sum_{i=1}^N \sum_{t=1}^T (\bar{z}_i - \bar{z})^2$$

avec $\bar{z}$ la moyenne totale :

$$\bar{z} = \frac{1}{NT} \sum_{i=1}^N \sum_{t=1}^T z_{it}$$

avec $\bar{z}_i$ la moyenne individuelle sur l'ensemble de la période :

$$\bar{z}_i = \frac{1}{T} \sum_{t=1}^T z_{it}$$

Décomposition de la variance

$$\sum_{i=1}^N \sum_{t=1}^T (z_{it} - \bar{z})^2 = \sum_{i=1}^N \sum_{t=1}^T (z_{it} - \bar{z}_i)^2 + \sum_{i=1}^N \sum_{t=1}^T (\bar{z}_i - \bar{z})^2$$

Variance Totale = variance des écarts aux moyennes individuelles +
variance des moyennes individuelles

Variance Totale = variance intra + variance inter

Décomposition de la variance

- ▶ Si la variance intra-individuelle est faible, la variabilité des données provient essentiellement des différences entre individus
- ▶ Si la variance inter-individuelle est faible, la variabilité des données provient essentiellement des évolutions dans le temps

Chapitre 1 : Cours

Chapitre 1 : Application

Manipulation des données de panel avec Stata

- ▶ Règles générales:
 - ▶ Enregistrer les bases de données originelles dans un dossier à part et ne plus y toucher
 - ▶ Créer des bases de données de travail dans un autre dossier
 - ▶ Garder la trace de toute manipulation de donnée (sous forme de do-file).
 - ▶ S'appuyer sur la commande *help* avant d'utiliser une commande avec laquelle on est peu familière
- ▶ Données de panel sous Stata:
 - ▶ Les données sont en format *wide* ou *long* : commande *reshape*
 - ▶ Le format préféré est *long* car il permet d'utiliser plus facilement l'ensemble de commandes *xt* de Stata.
 - ▶ Les données doivent être déclarées comme étant des données de panel avec la commande *xtset*
 - ▶ Description des données : commandes *xtdes* , *xtsum* et *xttab*

Manipulation des données de panel avec Stata

Données en coupe transversale:

idcode	year	wage	south	grade
1	1987	4693.399	0	12
2	1987	2153.419	0	12
3	1987	1451.804	0	12
4	1987	2345.687	0	17
6	1987	2598.673	0	12

Manipulation des données de panel avec Stata

Données de panel, format *wide*:

idcode	grade	wage87	wage88	wage89	south87	south88	south89
1	12	5000	5500	6000	0	1	0
2	12	2000	2200	3300	1	0	0
3	12	3000	2000	1000	0	0	1

Manipulation des données de panel avec Stata

Données de panel, format *long*

idcode	year	grade	wage	south
1	87	12	5000	0
1	88	12	5500	1
1	89	12	6000	0
2	87	12	2000	1
2	88	12	2200	0
2	89	12	3300	0
3	87	12	3000	0
3	88	12	2000	0
3	89	12	1000	1

Commande stata pour changer de format:

reshape long wage south, i(idcode) j(year)

Manipulation des données de panel avec Stata

- Définir la dimension panel dans les données:

xtset idcode

xtset idcode year

xtset idcode year, yearly

- Statistiques descriptives:

xtsum, xttab

Manipulation des données de panel avec Stata

```
. xtsum south grade
```

Variable		Mean	Std. dev.	Min	Max	Observations
south	overall	.4095562	.4917605	0	1	N = 28526
	between		.4667982	0	1	n = 4711
	within		.1597932	-.5237771	1.34289	T-bar = 6.05519
grade	overall	12.53259	2.323905	0	18	N = 28532
	between		2.566536	0	18	n = 4709
	within		0	12.53259	12.53259	T-bar = 6.05904

Manipulation des données de panel avec Stata

```
. xttab south
```

south	Overall		Between		Within
	Freq.	Percent	Freq.	Percent	Percent
0	16843	59.04	3104	65.89	91.50
1	11683	40.96	2147	45.57	87.14
Total	28526	100.00	5251	111.46	89.72

(n = 4711)